

LAPORAN TUGAS KONVERSI

IMPLEMENTASI *TEXT MINING* BERBASIS NLP UNTUK ANALISIS POLA KEGIATAN MAGANG STUDI INDEPENDEN VINIX7 BATCH 4

**Disusun guna memenuhi tugas konversi mata kuliah
Natural Language Processing**



**universitas
MALIKUSSALEH**

**Disusun Oleh:
SAFIRA KHALISHA
NIM: 230170175**

**Dosen Pengampu:
Dr. Eng., Defry Hamdhana, S.Kom., M.Kom**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS MALIKUSSALEH
LHOKSEUMAWE
2026**

ABSTRAK

Dokumentasi kegiatan harian peserta magang Studi Independen VINIX7 Batch 4 tersimpan dalam logbook mingguan berbentuk teks yang belum pernah dianalisis secara otomatis. Penelitian ini mengimplementasikan tiga teknik *Natural Language Processing* (NLP) secara kombinatorik untuk menganalisis pola kegiatan tiga anggota tim divisi Python Machine Learning selama 10 minggu, yaitu *K-Means Clustering*, *Latent Dirichlet Allocation* (LDA) *Topic Modeling*, dan *Cosine Similarity*. Dataset terdiri dari 166 entri logbook dari tiga peserta (Wardatul, Safira, Tri). *Pipeline* diawali dengan *preprocessing* menggunakan *PySastrawi* untuk teks berbahasa Indonesia, dilanjutkan representasi *TF-IDF* dengan 200 fitur, kemudian ketiga analisis dijalankan secara paralel. Hasil *K-Means* dengan $K=5$ mengelompokkan kegiatan menjadi kluster yang merepresentasikan pola kerja nyata seperti pengerjaan tugas teknis, sesi mentorship, dan penyusunan laporan. LDA menemukan 5 topik dominan yang mencerminkan progresivitas pembelajaran dari modul dasar *Python* hingga *MLOps* dan *deployment*. Analisis *Cosine Similarity* menunjukkan pasangan Safira dan Tri memiliki kesamaan pola kegiatan tertinggi (rata-rata 0,2817), sementara pasangan Safira dan Wardatul memiliki kesamaan terendah (0,1868), mengindikasikan adanya perbedaan gaya dokumentasi dan pembagian tugas antar anggota. Sistem ini terbukti mampu mengekstrak pola tersembunyi dari logbook yang sebelumnya hanya berfungsi sebagai dokumen administratif, sehingga berpotensi digunakan sebagai alat pemantauan partisipasi dan kontribusi peserta magang secara otomatis.

Kata Kunci: *Text Mining, K-Means Clustering, LDA Topic Modeling, Cosine Similarity, logbook magang, NLP bahasa Indonesia*

Link Github: https://github.com/safirakhalisha6-gif/Final_NLP_Stupen.git

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas segala rahmat dan karunia-Nya sehingga laporan tugas konversi mata kuliah *Natural Language Processing* (NLP) yang berjudul "**Implementasi *Text Mining* Berbasis NLP untuk Analisis Pola Kegiatan Magang Studi Independen VINIX7 Batch 4**" dapat diselesaikan dengan baik. Laporan ini disusun sebagai bentuk pertanggungjawaban akademis atas implementasi teknik NLP pada data logbook mingguan peserta program Magang dan Studi Independen Bersertifikat Mandiri di PT. Vinix Seven Aurum (VINIX7). Penulis berharap hasil analisis dalam laporan ini dapat memberikan kontribusi nyata bagi pengelolaan dan pemantauan program VINIX7 pada batch-batch selanjutnya.

Penulis mengucapkan terima kasih yang sebesar-besarnya kepada Bapak Dr. Eng., Defry Hamdhana, S.Kom., M.Kom selaku dosen pengampu mata kuliah *Natural Language Processing* atas bimbingan dan arahannya. Penulis menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi perbaikan di masa mendatang.

Lhokseumawe, 13 Juni 2026

Penulis

Safira Khalisha

DAFTAR ISI

ABSTRAK	i
KATA PENGANTAR.....	ii
DAFTAR ISI.....	iii
DAFTAR TABEL.....	v
DAFTAR GAMBAR.....	v
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	2
BAB 2 IDENTIFIKASI PELUANG NLP	3
2.1 Ketersediaan Data Teks.....	3
2.2 Masalah yang Dapat Diselesaikan dengan NLP	3
2.3 Solusi Berbasis NLP	4
BAB III DESAIN SOLUSI NLP	5
3.1 <i>Task</i> NLP.....	5
3.2 Alur Sistem.....	5
BAB IV IMPLEMENTASI	7
4.1 <i>Tools dan Environment</i>	7
4.2 <i>Preprocessing</i>	7
4.3 Representasi Teks: TF-IDF	8
4.4 <i>Task 1: K-Means Clustering</i>	8
4.5 <i>Task 2: LDA Topic Modeling</i>	9
4.6 <i>Task 3: Cosine Similarity</i>	9
BAB V HASIL DAN EVALUASI.....	10

5.1 Hasil <i>K-Means Clustering</i>	10
5.2 Hasil <i>LDA Topic Modelling</i>	12
5.3 Hasil <i>Cosine Similarity</i> Antar Anggota.....	14
5.4 Analisis Manfaat Terhadap <i>Project Stupen</i>	16
BAB VI REFLEKSI	17
6.1 Kendala yang Dihadapi	17
6.2 Potensi Pengembangan Lebih Lanjut.....	17
BAB VII KESIMPULAN DAN SARAN	19
7.1 Kesimpulan	19
7.2 Saran.....	20
DAFTAR PUSTAKA	21

DAFTAR GAMBAR

Gambar 1. Grafik <i>Elbow Method</i> untuk pemilihan K optimal	10
Gambar 2. Distribusi kluster kegiatan per anggota tim	11
Gambar 3. Visualisasi kluster pada ruang PCA 2D	11
Gambar 4. <i>Word cloud</i> per topik hasil LDA	12
Gambar 5. <i>Heatmap</i> distribusi topik dominan per minggu	12
Gambar 6. Grafik <i>Cosine Similarity</i> antar anggota per minggu	13
Gambar 7. <i>Heatmap Cosine Similarity</i> keseluruhan antar anggota	13

DAFTAR TABEL

Tabel 1. Distribusi data logbook per anggota tim VINIX7 Batch 4.....	3
Tabel 2. Alur sistem text mining logbook yang dirancang	6
Tabel 3. Distribusi entri per kluster hasil <i>K-Means</i>	10
Tabel 4. Rata-rata <i>Cosine Similarity</i> antar anggota tim	12

BAB I

PENDAHULUAN

1.1 Latar Belakang

Program Magang dan Studi Independen Bersertifikat (MSIB) merupakan salah satu program unggulan dalam kerangka Merdeka Belajar Kampus Merdeka (MBKM) yang memungkinkan mahasiswa memperoleh pengalaman kerja nyata di lingkungan industri. PT Vinix Seven Aurum (VINIX7) merupakan salah satu mitra penyelenggara MSIB yang menyediakan program pelatihan berbasis proyek di berbagai divisi teknis, termasuk divisi *Python Machine Learning*. Pada Batch 4, peserta diwajibkan mengisi logbook mingguan sebagai dokumentasi kegiatan harian selama program berlangsung. Setiap peserta mencatat kegiatan yang dilakukan setiap hari kerja dalam bentuk narasi teks, mencakup sesi briefing, pengerjaan tugas, diskusi tim, sesi mentorship, dan kegiatan softskill.

Meskipun logbook memiliki nilai dokumentasi yang tinggi, data teks yang terkumpul belum pernah dimanfaatkan lebih jauh selain sebagai dokumen administratif pengumpulan tugas. Padahal, menurut Feldman dan Sanger (2021), dokumen teks terstruktur seperti logbook kerja menyimpan pola informasi laten yang dapat diekstrak menggunakan teknik text mining untuk menghasilkan insight yang bermakna bagi pengelola program. Dengan jumlah peserta yang terus bertambah setiap batch, pemantauan manual terhadap kualitas dan distribusi kegiatan masing-masing anggota tim menjadi semakin tidak efisien.

Permasalahan utama yang ditemukan dalam pengelolaan program VINIX7 adalah tidak adanya mekanisme otomatis untuk mengetahui bagaimana pola kegiatan anggota tim terdistribusi, topik apa yang paling sering dikerjakan di setiap tahap program, dan seberapa selaras kegiatan antar anggota dalam satu kelompok kerja. Informasi ini penting bagi koordinator program untuk mengevaluasi efektivitas pembagian tugas dan memastikan setiap peserta mendapatkan pengalaman belajar yang merata.

Pendekatan *Natural Language Processing* (NLP), khususnya kombinasi teknik *unsupervised text mining* yaitu *K-Means Clustering*, *Latent Dirichlet Allocation* (LDA), dan *Cosine Similarity*, dipilih sebagai solusi karena data logbook

tidak memiliki label kategori yang telah ditentukan sebelumnya. Teknik unsupervised memungkinkan penemuan pola secara otomatis dari teks mentah tanpa memerlukan proses anotasi manual yang membutuhkan waktu dan biaya besar (Manning et al., 2019).

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah:

1. Jenis kegiatan apa saja yang dapat dikelompokkan secara otomatis dari entri logbook magang peserta VINIX7 Batch 4 menggunakan *K-Means Clustering*?
2. Topik-topik dominan apa yang muncul dari keseluruhan logbook selama 10 minggu program berlangsung berdasarkan analisis *LDA Topic Modeling*?
3. Seberapa besar kesamaan pola kegiatan antar anggota tim divisi *Python Machine Learning* berdasarkan analisis *Cosine Similarity*?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Mengelompokkan 166 entri logbook magang dari tiga peserta VINIX7 Batch 4 ke dalam kluster-kluster kegiatan yang bermakna menggunakan algoritma *K-Means*.
2. Mengidentifikasi topik-topik dominan yang muncul secara laten dalam keseluruhan logbook selama 10 minggu menggunakan *LDA Topic Modeling*.
3. Mengukur tingkat kesamaan pola kegiatan antar anggota tim per minggu menggunakan *Cosine Similarity* berbasis TF-IDF.

BAB II

IDENTIFIKASI PELUANG NLP

2.1 Ketersediaan Data Teks

Dataset yang digunakan dalam penelitian ini terdiri dari 166 entri logbook mingguan dari tiga peserta program Studi Independen VINIX7 Batch 4 divisi *Python Machine Learning*, yaitu Wardatul A'ani, Safira Khalisha, dan Tri Mayluddin Villanda. Data mencakup kegiatan harian selama 10 minggu program, dari minggu pertama (Februari 2026) hingga minggu kesepuluh (Mei 2026). Distribusi data per anggota disajikan pada Tabel 1.

Tabel 1. Distribusi data logbook per anggota tim VINIX7 Batch 4

Anggota	Jumlah Entri	Keterangan
Wardatul A'ani	50	5 entri per minggu, konsisten
Safira Khalisha	66	Lebih detail, beberapa hari terdapat 2 entri (sesi berbeda)
Tri Mayluddin Villanda	50	5 entri per minggu, konsisten
Total	166	Minggu 1–10

Setiap entri logbook berisi deskripsi kegiatan harian dalam bahasa Indonesia dengan panjang teks bervariasi antara 30 hingga 400 karakter. Data dikumpulkan dari tiga file dokumen (.docx) yang kemudian diekstrak dan disimpan dalam format CSV dengan kolom nama, minggu, hari_tanggal, dan deskripsi.

2.2 Masalah yang Dapat Diselesaikan dengan NLP

Terdapat tiga masalah utama dalam pengelolaan logbook VINIX7 yang dapat diselesaikan melalui pendekatan NLP, yaitu:

1. Tidak ada kategorisasi otomatis terhadap jenis kegiatan yang dicatat peserta. Selama ini, logbook hanya dibaca secara manual oleh koordinator tanpa adanya ringkasan pola kegiatan yang terstruktur. *K-Means Clustering* dapat mengelompokkan entri serupa secara otomatis.

2. Tidak diketahui topik atau tema apa yang paling banyak dikerjakan di setiap fase program. *LDA Topic Modeling* mampu mengungkap topik-topik laten yang tersembunyi di balik narasi teks logbook tanpa memerlukan label.
3. Tidak ada tolok ukur kuantitatif untuk menilai seberapa selaras kegiatan antar anggota tim. *Cosine Similarity* dapat memberikan nilai numerik yang objektif untuk mengukur kedekatan pola kegiatan antar peserta per minggu.

2.3 Solusi Berbasis NLP

Task NLP yang dipilih adalah kombinasi tiga teknik *unsupervised text mining* yang saling melengkapi, berbeda dengan analisis berbasis label yang memerlukan data anotasi. Ketiga teknik ini dapat langsung diterapkan pada teks mentah logbook.

Kombinasi *K-Means*, *LDA*, dan *Cosine Similarity* dipilih karena masing-masing menjawab pertanyaan yang berbeda namun saling melengkapi: *K-Means* menjawab "apa jenis kegiatannya?", *LDA* menjawab "apa topiknya?", dan *Cosine Similarity* menjawab "seberapa mirip antar anggota?".

BAB III

DESAIN SOLUSI NLP

3.1 Task NLP

Penelitian ini mengimplementasikan tiga *sub-task* NLP secara kombinatif:

1. *K-Means Clustering*, yaitu algoritma pengelompokan (*clustering*) berbasis jarak yang mengelompokkan entri logbook ke dalam K kluster berdasarkan kemiripan representasi TF-IDF-nya. Kluster yang terbentuk merepresentasikan jenis-jenis kegiatan dominan selama magang.
2. *Latent Dirichlet Allocation (LDA) Topic Modeling*, yaitu model probabilistik generatif yang mengasumsikan setiap dokumen merupakan campuran dari beberapa topik laten, dan setiap topik dicirikan oleh distribusi kata. LDA digunakan untuk menemukan tema-tema besar yang muncul sepanjang 10 minggu program.
3. *Cosine Similarity*, yaitu metrik kemiripan yang mengukur sudut kosinus antara dua vektor TF-IDF. Nilai mendekati 1 berarti sangat mirip, nilai mendekati 0 berarti sangat berbeda. Metrik ini digunakan untuk membandingkan pola kegiatan antar anggota tim per minggu.

3.2 Alur Sistem

Alur sistem *text mining* yang dirancang terdiri dari enam tahap utama, sebagaimana dirangkum pada Tabel 2.

Tabel 2. Alur sistem *text mining* logbook yang dirancang

Tahap	Proses	Output
<i>Input</i>	File CSV logbook (166 entri, 3 anggota, 10 minggu)	<i>Raw text</i>
<i>Preprocessing</i>	<i>Case folding</i> → <i>Cleaning</i> → Tokenisasi → <i>Stopword removal</i> → <i>Stemming</i>	Teks bersih + token
Representasi	TF-IDF <i>Vectorizer</i> (200 fitur, <i>unigram+bigram</i>)	Matriks 166×200

Tahap	Proses	<i>Output</i>
Task 1	<i>K-Means Clustering</i> (K=5, <i>Elbow Method</i>) + PCA 2D	Label kluster per entri
Task 2	<i>LDA Topic Modeling</i> (5 topik, 15 <i>passes</i>)	Topik dominan per entri
Task 3	<i>Cosine Similarity</i> per minggu per pasangan	Nilai similaritas 0–1
<i>Output</i>	Visualisasi + ringkasan pola kegiatan tim	Tabel + grafik + kesimpulan

BAB IV IMPLEMENTASI

4.1 *Tools dan Environment*

Implementasi dilakukan menggunakan Python 3 dalam lingkungan Google Colaboratory. Berikut *library* yang digunakan:

1. PySastrawi, *stopword removal* dan *stemming* bahasa Indonesia
2. Scikit-learn, TF-IDF *vectorizer*, K-Means *Clustering*, PCA, dan *Cosine Similarity*
3. Gensim, LDA *Topic Modeling*
4. Matplotlib, Seaborn, visualisasi data
5. WordCloud, visualisasi kata per topik
6. Pandas, NumPy, manipulasi dan analisis data

Repository proyek https://github.com/safirakhalisha6-gif/Final_NLP_Stupen.git

4.2 *Preprocessing*

Pipeline preprocessing diterapkan pada kolom deskripsi setiap entri logbook sebelum dianalisis. Berikut penjelasan masing-masing tahap:

1. *Case folding* adalah tahap mengubah seluruh karakter teks ke huruf kecil untuk menghindari duplikasi token akibat perbedaan kapitalisasi, misalnya "Zoom" dan "zoom" diperlakukan sama.
2. *Cleaning* adalah tahap menghapus karakter non-alfabet, angka, tanda baca, dan simbol yang tidak relevan menggunakan ekspresi reguler.
3. Tokenisasi adalah tahap memecah teks menjadi daftar token (kata) individual menggunakan metode *split* pada teks yang telah dibersihkan.
4. *Stopword removal* adalah tahap menghapus kata-kata umum yang tidak bermakna menggunakan kamus *stopword* PySastrawi, dilengkapi kamus *stopword* kustom yang spesifik terhadap konteks logbook magang seperti 'zoom', 'mengikuti', 'sesi', 'bersama', 'magang', dan 'mentor'.
5. *Stemming* adalah tahap mengubah token ke bentuk dasar kata menggunakan algoritma ECS *Stemmer* via PySastrawi untuk menyamakan variasi

morfologis, misalnya 'mengerjakan', 'dikerjakan', dan 'pekerjaan' menjadi 'kerja'.

Contoh hasil *preprocessing* pada satu entri logbook:

- **Asli:** Mengikuti sesi Zoom onboarding yang diadakan tim koordinator magang. Kegiatan ini berisi pengenalan dan pengarahan umum mengenai alur kerja divisi...
- **Bersih:** onboarding ada koordinator giat isi kenal arah umum alur divisi ekspektasi penuh jalan

4.3 Representasi Teks: TF-IDF

Teks yang telah diproses diubah ke representasi numerik menggunakan TF-IDF (*Term Frequency-Inverse Document Frequency*) *Vectorizer* dari pustaka *Scikit-learn*. TF-IDF memberikan bobot tinggi pada kata yang sering muncul dalam suatu dokumen tetapi jarang muncul di seluruh korpus, sehingga kata-kata yang bersifat diskriminatif lebih ditonjolkan. Parameter yang digunakan adalah *max_features*=200, *min_df*=2, *max_df*=0,85, dan *ngram_range*=(1,2) untuk menangkap kombinasi *unigram* dan *bigram*. Hasilnya adalah matriks fitur berukuran 166×200. Contoh fitur yang dihasilkan mencakup: 'algoritma apriori', 'bangun pipeline', 'base model', 'benchmarking', 'cosine similarity', 'decision tree', dan 'feature engineering'.

4.4 Task 1: K-Means Clustering

K-Means adalah algoritma *clustering* yang mengelompokkan data ke dalam K kluster dengan meminimalkan nilai *inertia* (jumlah kuadrat jarak titik data ke pusat klusternya). Penentuan K optimal dilakukan menggunakan *Elbow Method*, yaitu memilih nilai K di mana penurunan *inertia* mulai melambat membentuk "siku". Setelah K optimal ditentukan, model dilatih dengan *random_state*=42 dan *n_init*=10 untuk memastikan kestabilan hasil. Untuk visualisasi, representasi TF-IDF direduksi menjadi 2 dimensi menggunakan *Principal Component Analysis* (PCA) sehingga distribusi kluster dapat divisualisasikan dalam grafik *scatter plot* 2D.

4.5 Task 2: LDA Topic Modeling

LDA (*Latent Dirichlet Allocation*) adalah model probabilistik generatif yang mengasumsikan setiap dokumen merupakan campuran dari beberapa topik laten, di mana setiap topik dicirikan oleh distribusi probabilitas atas seluruh kata dalam kosakata. Implementasi menggunakan pustaka Gensim dengan parameter *num_topics=5*, *passes=15*, *random_state=42*, dan *alpha='auto'* untuk estimasi parameter *alpha* secara otomatis. Sebelum melatih model LDA, dibuat *dictionary* dan *corpus* dalam format *bag-of-words* dari hasil tokenisasi. Kata-kata yang terlalu jarang (*no_below=2*) atau terlalu umum (*no_above=0,8*) difilter dari *dictionary*. Hasil LDA divisualisasikan menggunakan *word cloud* untuk setiap topik dan *heatmap* distribusi topik dominan per minggu.


4.6 Task 3: Cosine Similarity

Cosine Similarity digunakan untuk mengukur kesamaan pola kegiatan antar anggota tim. Untuk setiap minggu, teks logbook masing-masing anggota digabungkan menjadi satu dokumen, kemudian direpresentasikan menggunakan TF-IDF terpisah (*max_features=300*). Nilai *Cosine Similarity* dihitung antar semua pasangan anggota (Safira–Tri, Safira–Wardatul, Tri–Wardatul) menggunakan fungsi *cosine_similarity* dari Scikit-learn. Proses ini diulang untuk setiap minggu sehingga diperoleh tren kesamaan kegiatan sepanjang 10 minggu program. Selain per minggu, dihitung pula nilai similaritas keseluruhan dengan menggabungkan seluruh teks logbook per anggota.

BAB V

HASIL DAN EVALUASI

5.1 Hasil K-Means Clustering



Gambar 1. *Elbow Method*-Pemilihan K Optimal


Berdasarkan *Elbow Method* diatas , K=5 dipilih sebagai jumlah kluster optimal karena penurunan *inertia* mulai melambat secara signifikan pada titik tersebut. Hasil K-Means dengan K=5 menghasilkan distribusi kluster sebagaimana disajikan pada Tabel 3.

Tabel 3. Distribusi entri per kluster hasil K-Means

Kluster	Jumlah Entri	Persentase	Interpretasi Kegiatan
Kluster 0	43	25,9%	Pengerjaan tugas teknis & implementasi kode
Kluster 1	11	6,6%	Evaluasi, finalisasi, dan pengumpulan tugas
Kluster 2	30	18,1%	Sesi briefing & mentorship bersama mitra
Kluster 3	73	44,0%	Diskusi tim, pembagian tugas & kolaborasi
Kluster 4	9	5,4%	Pembelajaran mandiri & riset eksplorasi


Kluster 3 merupakan kluster terbesar (44,0%) yang merepresentasikan kegiatan diskusi tim dan kolaborasi, mencerminkan bahwa kegiatan program

VINIX7 sangat menekankan kerja tim. Kluster 0 (25,9%) merepresentasikan kegiatan teknis seperti implementasi kode Python, *pipeline*, dan *modeling*, yang konsisten dengan divisi *Python Machine Learning*. Kluster 4 merupakan yang terkecil (5,4%), menunjukkan bahwa kegiatan pembelajaran mandiri relatif sedikit dibandingkan kegiatan berbasis tim.



Gambar 2. Visualisasi Distribusi *Cluster* per Anggota


Visualisasi Distribusi *Cluster* per Anggota diatas menunjukkan bahwa Safira memiliki proporsi kluster 2 (sesi briefing dan mentorship) yang lebih tinggi dibandingkan dua anggota lain, konsisten dengan gaya penulisan logbook Safira yang lebih detail dalam mencatat sesi-sesi formal.



Gambar 3. Visualisasi PCA 2D

Sementara pada Visualisasi PCA 2D, memperlihatkan pemisahan kluster yang cukup baik meskipun terdapat tumpang tindih pada beberapa entri, yang wajar mengingat logbook magang memiliki konteks tematik yang saling berdekatan.

5.2 Hasil LDA Topic Modelling




Gambar 4. Visualisasi Word Cloud per Topik

LDA dengan 5 topik berhasil mengidentifikasi tema-tema dominan yang muncul sepanjang 10 minggu program. Berikut interpretasi kata kunci utama per topik:

1. Topik 1 (*model, analisis, hasil, giat*): Kegiatan analisis dan evaluasi model *machine learning*, mencerminkan tahap pengerjaan tugas pada

modul 6–9 yang berfokus pada *Decision Tree*, *Random Forest*, *Boosting*, dan *Association Rules*.

2. Topik 2 (*data, pipeline, kelompok, learn*): Kegiatan membangun *pipeline* dan pengolahan data, merepresentasikan modul 2–5 yang berfokus pada *data transformation*, *feature engineering*, dan *Scikit-learn pipeline*.
3. Topik 3 (*giat, hasil, model, sesuai*): Kegiatan pengecekan kode, validasi hasil, dan memastikan output sesuai instruksi tugas, yang mencerminkan peran *quality check* yang umum dilakukan oleh anggota tim.
4. Topik 4 (*feature, fokus, tentu, giat*): Kegiatan pembagian tugas dan penentuan fokus pengerjaan per anggota, merepresentasikan proses koordinasi internal tim setiap minggu.
5. Topik 5 (*data, mentorship, decision, tree*): Kegiatan sesi formal bersama mentor terkait materi teknis spesifik seperti *Decision Tree* dan *Predictive Maintenance*.




Gambar 5. *Heatmap* distribusi topik dominan per minggu

Heatmap distribusi topik dominan per minggu diatas menunjukkan progresivitas yang jelas: Topik 2 (*pipeline* dan pengolahan data) dominan pada


minggu awal (1–4), beralih ke Topik 1 dan 5 (analisis model dan mentorship teknis) pada minggu pertengahan (5–8), dan Topik 3 (validasi dan finalisasi) meningkat pada minggu akhir (9–10). Pola ini konsisten dengan progresivitas kurikulum VINIX7 dari dasar Python menuju MLOps dan *deployment*.

5.3 Hasil *Cosine Similarity* Antar Anggota



Gambar 6. Grafik *Cosine Similarity* per minggu

Grafik gambar diatas menunjukkan fluktuasi yang cukup besar antar minggu. Nilai similaritas cenderung meningkat pada minggu di mana seluruh anggota tim mengikuti sesi *briefing* dan mentorship yang sama (minggu 3, 6, 9), karena ketiga anggota mencatat kegiatan sesi formal yang serupa. Sebaliknya, nilai similarity menurun pada minggu-minggu di mana pembagian tugas antar anggota lebih spesifik sehingga masing-masing mencatat kegiatan yang berbeda.



Gambar 7. *Heatmap Cosine Similarity* keseluruhan

Kemudian pada, *Heatmap Cosine Similarity* keseluruhan mengonfirmasi bahwa pasangan Safira dan Tri memiliki kesamaan tertinggi (0,2817), sementara pasangan Safira dan Wardatul memiliki kesamaan terendah (0,1868). Perbedaan ini sebagian besar disebabkan oleh perbedaan gaya penulisan logbook: Safira cenderung menulis dengan format yang lebih detail dan terstruktur per sesi, sementara Wardatul cenderung mencatat kegiatan teknis dengan istilah kode dan fungsi Python yang lebih spesifik.

Dari hasil *Cosine Similarity* tersebut dapat disimpulkan dan disajikan dengan table rata-ata dibawah ini.

Tabel 4. Rata-rata *Cosine Similarity* antar anggota tim

Pasangan	Rata-rata <i>Similarity</i>	Interpretasi
Safira vs Tri	0,2817	Tertinggi — pola kegiatan paling mirip
Tri vs Wardatul	0,2789	Mirip — selisih tipis dengan pasangan Safira-Tri
Safira vs Wardatul	0,1868	Terendah — gaya penulisan paling berbeda

5.4 Analisis Manfaat Terhadap *Project Stupen*

Solusi *text mining* yang diimplementasikan terbukti menghasilkan insight yang tidak dapat diperoleh dari pembacaan logbook secara manual. Dengan sistem ini, koordinator program VINIX7 kini dapat mengetahui secara otomatis:

1. Kegiatan terbesar yang dilakukan peserta adalah diskusi tim dan kolaborasi (44%), menunjukkan program sangat menekankan teamwork.
2. Terdapat progresivitas topik yang jelas dari modul dasar menuju *MLOps*, mengkonfirmasi kurikulum berjalan sesuai rencana.
3. Nilai *Cosine Similarity* yang relatif rendah (0,18–0,28) menunjukkan setiap anggota memiliki kontribusi dan perspektif yang cukup unik dalam tim.
4. Sistem dapat dikembangkan menjadi alat pemantauan otomatis untuk mendeteksi apabila ada anggota tim yang kegiatan logbook-nya sangat berbeda dari anggota lain, yang bisa menjadi indikator awal masalah partisipasi.

BAB VI

REFLEKSI

6.1 Kendala yang Dihadapi

Selama proses implementasi penelitian ini, terdapat beberapa kendala signifikan yang dihadapi, yaitu:

1. Tidak adanya label kategori pada dataset menyebabkan interpretasi kluster *K-Means* dan topik LDA harus dilakukan secara manual berdasarkan kata kunci yang muncul, sehingga interpretasi bersifat subjektif dan bergantung pada pemahaman peneliti terhadap konteks program.
2. Proses *stemming* menggunakan *PySastrawi* membutuhkan waktu yang lebih lama (~2–3 menit untuk 166 entri) dibandingkan *stopword removal* saja, dan kadang menghasilkan stem yang kurang akurat untuk istilah teknis seperti *benchmarking*, *clustering*, dan *pipeline* yang merupakan kata serapan bahasa Inggris.
3. Gaya penulisan logbook yang sangat berbeda antar anggota (Safira lebih deskriptif, Wardatul lebih teknis, Tri lebih ringkas) menyulitkan perbandingan *Cosine Similarity* yang adil, karena perbedaan nilai *similarity* bisa mencerminkan perbedaan gaya penulisan, bukan perbedaan kegiatan yang sesungguhnya.
4. Jumlah data yang relatif kecil (166 entri) membatasi performa LDA dalam membentuk topik yang benar-benar *distinct*, sehingga beberapa topik memiliki kata kunci yang tumpang tindih.

6.2 Potensi Pengembangan Lebih Lanjut

Berdasarkan keterbatasan yang ditemukan, beberapa arah pengembangan yang direkomendasikan adalah:

1. Penambahan fitur anotasi semi-otomatis menggunakan *zero-shot classification* berbasis model bahasa besar (LLM) untuk memberikan label kategori pada setiap entri logbook, sehingga evaluasi kluster dapat dilakukan secara lebih objektif menggunakan metrik seperti *Adjusted Rand Index* (ARI).

2. Pengembangan *dashboard* web berbasis Streamlit atau Flask yang memungkinkan koordinator VINIX7 memantau pola kegiatan tim secara *real-time* setiap minggu tanpa perlu menjalankan kode Python secara manual.
3. Perluasan dataset dengan menggabungkan logbook dari seluruh kelompok dalam satu divisi (bukan hanya tiga anggota satu kelompok) untuk mendapatkan gambaran yang lebih representatif tentang pola kegiatan divisi *Python Machine Learning* secara keseluruhan.
4. Penerapan *Word2Vec* atau *IndoBERT Embeddings* sebagai alternatif TF-IDF untuk representasi teks yang lebih mampu menangkap kemiripan semantik, bukan hanya kemiripan leksikal, sehingga entri logbook dengan maksud serupa namun menggunakan kata berbeda tetap dapat dikelompokkan bersama.
5. Eksplorasi metode *Hierarchical Clustering* sebagai pelengkap *K-Means* untuk memvisualisasikan hierarki kemiripan antar entri melalui dendrogram, yang dapat memberikan perspektif tambahan tentang struktur kegiatan magang.

BAB VII

KESIMPULAN DAN SARAN

7.1 Kesimpulan

Berdasarkan implementasi dan evaluasi yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut:

1. Penelitian ini berhasil mengimplementasikan kombinasi tiga teknik NLP *unsupervised*, yaitu *K-Means Clustering*, *LDA Topic Modeling*, dan *Cosine Similarity*, pada 166 entri logbook magang dari tiga peserta divisi *Python Machine Learning VINIX7 Batch 4* selama 10 minggu program.
2. *K-Means Clustering* dengan $K=5$ berhasil mengelompokkan kegiatan magang ke dalam lima kluster yang bermakna. Kluster terbesar adalah diskusi tim dan kolaborasi (44,0%), diikuti pengerjaan tugas teknis (25,9%), sesi *briefing* dan mentorship (18,1%), evaluasi dan finalisasi (6,6%), serta pembelajaran mandiri (5,4%). Komposisi ini mencerminkan program VINIX7 yang sangat berorientasi pada kerja tim dan implementasi teknis.
3. *LDA Topic Modeling* dengan 5 topik mengungkap adanya progresivitas topik yang jelas sepanjang 10 minggu: dari topik pengolahan data dan *pipeline* di minggu awal, beralih ke topik analisis model dan evaluasi di minggu pertengahan, hingga topik finalisasi dan *deployment* di minggu akhir. Pola ini mengkonfirmasi kurikulum VINIX7 berjalan sesuai rancangan pembelajaran yang terstruktur.
4. Analisis *Cosine Similarity* menunjukkan bahwa pasangan Safira dan Tri memiliki kesamaan pola kegiatan tertinggi (0,2817), sementara pasangan Safira dan Wardatul memiliki kesamaan terendah (0,1868). Nilai kesamaan yang relatif rendah secara umum mengindikasikan bahwa setiap anggota memiliki kontribusi yang cukup unik dalam tim, baik karena pembagian tugas maupun gaya penulisan logbook yang berbeda.
5. Sistem *text mining* yang dibangun terbukti mampu mengekstrak *insight* yang bermakna dari data logbook yang sebelumnya hanya berfungsi sebagai dokumen administratif, sehingga berpotensi

dikembangkan menjadi alat pemantauan partisipasi peserta magang secara otomatis oleh koordinator VINIX7.

7.2 Saran

Berdasarkan hasil penelitian, saran yang dapat diberikan adalah:

1. VINIX7 disarankan untuk menstandarisasi format penulisan logbook antar peserta agar analisis NLP berbasis *Cosine Similarity* menghasilkan perbandingan yang lebih adil dan representatif.
2. Penelitian selanjutnya disarankan untuk menggunakan representasi teks berbasis *embedding* seperti *IndoBERT* agar dapat menangkap kemiripan semantik yang lebih dalam dibandingkan TF-IDF yang hanya berbasis kemunculan kata.
3. Koordinator program VINIX7 disarankan untuk memanfaatkan hasil *clustering* sebagai umpan balik kepada peserta agar dapat merefleksikan distribusi jenis kegiatan yang telah dilakukan selama magang.
4. Perlu dipertimbangkan pengembangan sistem otomatis yang dapat membaca dan menganalisis logbook secara berkala setiap minggu, sehingga potensi masalah partisipasi anggota tim dapat dideteksi lebih awal.

DAFTAR PUSTAKA

- Feldman, R., & Sanger, J. (2021). *The text mining handbook: Advanced approaches in analyzing unstructured data*. Cambridge University Press.
- Manning, C. D., Raghavan, P., & Schütze, H. (2019). *Introduction to information retrieval*. Cambridge University Press. <https://nlp.stanford.edu/IR-book/>
- Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022.
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281–297.
- Rahutomo, F., Kitasuka, T., & Aritsugi, M. (2012). Semantic cosine similarity. *Proceedings of the 7th International Student Conference on Advanced Science and Technology*, 4(1).
- Koto, F., Rahmadhani, A., & Cahyawijaya, S. (2020). IndoNLU benchmark and IndoBERT pre-trained model. *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics (AACL)*, 1–10.
- Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Koto, F., & Fung, P. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the ACL (AACL)*, 843–857.
- Scikit-learn Developers. (2023). *KMeans* – *sklearn.cluster*. Scikit-learn Documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html> (Diakses 15 Mei 2026)
- Scikit-learn Developers. (2023). *TfidfVectorizer* – *sklearn.feature_extraction.text*. Scikit-learn Documentation. https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html (Diakses 15 Mei 2026)

Řehůřek, R., & Sojka, P. (2010). Software framework for topic modelling with large corpora. *Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks*, 45–50.